3.30 汇报（三篇方法论）about Distributionally Robust Optimization

1 论文一：Distributionally Robust Mean-Variance Portfolio Selection with Wasserstein Distances

1.1 研究问题与基本动机

这篇文章研究的是**数据驱动的均值–方差投资组合选择**。与标准 Markowitz 模型不同，作者强调**模型不确定性**：投资者并不知道真实收益分布 P^*，只能从历史样本构造经验分布 P_n。由于经验分布与真实分布之间可能存在偏差，特别是均值估计通常很不稳定，直接基于 P_n 做 Markowitz 优化，往往会导致样本内表现很好、样本外表现较差的结果。

经典的 Markowitz 模型为

$$\min_{\phi\in\mathbb{R}^d}\left\{\phi^T\mathrm{Var}_{P^*}(R)\phi : \phi^T\mathbf{1}=1,\ \phi^T E_{P^*}(R)=\rho\right\},$$

其中 R 为 d 维资产收益向量，ϕ 为投资组合权重，ρ 为目标收益率。该模型的问题不在形式本身，而在于 $E_{P^*}(R)$ 和 $\mathrm{Var}_{P^*}(R)$ 在现实中都未知，只能由样本估计替代，因此最优解对估计误差非常敏感。

1.2 分布鲁棒模型的基本形式

为处理这种估计误差，作者采用**分布鲁棒优化**（distributionally robust optimization, DRO）的思路：不再完全相信经验分布 P_n，而是假设真实分布落在 P_n 周围某个不确定集合内。由此提出如下模型：

$$\min_{\phi\in F_{\delta,\bar\alpha}(n)}\ \max_{P\in U_\delta(P_n)}\left\{\phi^T\mathrm{Var}_P(R)\phi\right\}.$$

这里有两个核心对象。首先是不确定集

$$U_\delta(P_n)=\{P : D_c(P,P_n)\le\delta\},$$

即所有与经验分布 P_n 的距离不超过 δ 的概率分布所构成的集合。它可以理解为围绕 P_n 的一个 Wasserstein 球，δ 越大，表示允许的分布偏离越大，模型也越保守。

其次是可行域

$$F_{\delta,\bar\alpha}(n)=\left\{\phi : \phi^T\mathbf{1}=1,\ \min_{P\in U_\delta(P_n)} E_P(\phi^T R)\ge\bar\alpha\right\}.$$

这表示投资组合不仅要满足预算约束 $\phi^T\mathbf{1}=1$，还要保证在**最坏情况分布**下，其期望收益率仍不低于 $\bar\alpha$。

因此，整个模型的含义是：在所有“最坏情况下收益仍达标”的投资组合中，选取一个使“最坏情况下方差”最小的组合。

1.3 Wasserstein 距离与不确定集的含义

文中使用 Wasserstein 距离来刻画经验分布附近的分布不确定性。其一般形式为

$$D_c(P,Q) := \inf\{E_\pi[c(U,W)] : \pi_U = P,\ \pi_W = Q\},$$

其中 π 是联合分布，边缘分布分别为 P 和 Q，而 $c(U,W)$ 是把样本点 U 运输到 W 的代价。

直观上，Wasserstein 距离衡量的是：把一个分布“搬运”成另一个分布所需要付出的最小总成本。文中选取的运输成本为

$$c(u,w) = \|w-u\|_q^2.$$

这一设定非常关键，因为它会在后续优化中自然导出一个 p-范数正则项，其中 p 与 q 互为共轭指数，即

$$\frac{1}{p}+\frac{1}{q}=1.$$

也正因为如此，Wasserstein 球与范数正则化之间建立了直接联系。

1.4 第一个关键结果：鲁棒收益约束的显式形式

原始模型中的可行域包含约束

$$\min_{P\in U_\delta(P_n)} E_P(\phi^T R) \geq \bar{\alpha}.$$

作者首先对这一项进行化简，并证明

$$\min_{P\in U_\delta(P_n)} E_P(\phi^T R) = E_{P_n}(\phi^T R) - \sqrt{\delta}\|\phi\|_p.$$

因此，可行域可改写为

$$F_{\delta,\bar{\alpha}}(n) = \left\{\phi : \phi^T\mathbf{1}=1,\ E_{P_n}(\phi^T R) \geq \bar{\alpha} + \sqrt{\delta}\|\phi\|_p\right\}.$$

这个结果的含义很清楚：经验分布下的期望收益并不能直接代表最坏情况下仍能保证的收益；一旦考虑 Wasserstein 球中的分布偏移，收益需要扣除一个“安全边际”，其形式正好是 $\sqrt{\delta}\|\phi\|_p$。因此，鲁棒收益约束本质上是在经验收益约束上加入了一个由不确定性和投资组合范数共同决定的修正项。

1.5 第二个关键结果：鲁棒方差等价于正则化目标

文章最核心的理论结果，是把最坏情形方差优化转化为一个显式的正则化问题。作者证明：

$$\min_{\phi\in F_{\delta,\bar{\alpha}}(n)} \max_{P\in U_\delta(P_n)} \left\{\phi^T \mathrm{Var}_P(R)\phi\right\}$$

等价于

$$\min_{\phi\in F_{\delta,\bar{\alpha}}(n)} \left(\sqrt{\phi^T \mathrm{Var}_{P_n}(R)\phi} + \sqrt{\delta}\|\phi\|_p\right)^2.$$

这两个问题具有相同的最优值和最优解。换句话说，所谓“在 Wasserstein 球中对最坏情况方差做优化”，最终等价于一个经验方差加正则项的优化问题。这里出现的正则项并不是人为附加的技巧，而是从分布鲁棒模型中自然推导出来的。

这一点正是本文最有价值的理论贡献：它严格建立了

$$\text{分布鲁棒优化} \quad \Longleftrightarrow \quad \text{正则化优化}$$

之间的联系，从而为金融中的正则化投资组合选择提供了清晰的理论基础。

1.6 参数 δ 与 $\bar{\alpha}$ 的经济含义

在模型中，δ 和 $\bar{\alpha}$ 是两个最关键的参数。

参数 δ 决定 Wasserstein 球的半径，也就是不确定集 $U_\delta(P_n)$ 的大小。它衡量的是我们允许真实分布偏离经验分布到什么程度。δ 越大，不确定集越大，对手分布可扭曲的范围越广，模型越保守；δ 越小，模型越接近普通经验优化。因此，δ 实际上控制了鲁棒性与保守性之间的平衡。

参数 $\bar{\alpha}$ 则是鲁棒意义下的目标收益率。与经典 Markowitz 模型中的 ρ 不同，$\bar{\alpha}$ 强调的是：即使在最坏情况分布下，投资组合仍应达到的最低收益门槛。由于最坏情况收益一定低于经验收益，因此一般应有

$$\bar{\alpha} < \rho.$$

也就是说，分布鲁棒模型要求用更现实的方式设定收益目标，而不是简单沿用名义模型中的目标收益率。

1.7 数据驱动地选择 δ

提出鲁棒模型之后，一个重要问题是：δ 不应被任意设定，而应有数据驱动的选择方法。作者的第二个主要贡献，就是利用 robust Wasserstein profile inference（RWPI）为 δ 提供统计上的选择依据。

其基本思路是：构造的 Wasserstein 球既要足够大，从而以较高概率覆盖真实最优解所对应的信息；又不能过大，否则会使模型过度保守。通过分析 robust Wasserstein profile function 的渐近性质，作者得到

$$\delta_n = O(n^{-1}).$$

这意味着，不确定集半径应随着样本量增加而以 $1/n$ 的速度缩小。这个结论非常符合统计直觉：样本越多，对真实分布越有把握，因此需要考虑的不确定范围越小。

更进一步，作者还利用极限分布和给定置信水平来构造 δ_n 的选取方法，使 δ 不再只是经验调参量，而具有明确的统计解释。

1.8 数据驱动地选择 $\bar{\alpha}$

在确定 δ 之后，作者进一步讨论 $\bar{\alpha}$ 的设定。文章指出，不能简单取 $\bar{\alpha} = \rho$，而应根据分布不确定性对目标收益率进行下调。其基本形式为

$$\bar{\alpha} = \rho - \sqrt{\delta}\|\phi^*\|_p\, v_0,$$

其中 v_0 是由统计推断决定的常数，ϕ^* 是真实最优投资组合。

这个表达式说明：原始目标收益率 ρ 需要扣除一个与 $\sqrt{\delta}$ 成比例的调整项。不确定性越大，这个调整就越大，因此鲁棒收益门槛也应相应降低。作者进一步结合中心极限定理，给出 v_0 的统计选择方法，从而使 $\bar{\alpha}$ 的设定同样具备数据驱动的依据。

1.9 论文主线总结

这篇论文的逻辑主线可以概括为以下几步。首先，作者指出经典 Markowitz 模型对均值和协方差估计误差非常敏感，因而样本外表现不稳定。其次，文章用 Wasserstein 球刻画经验分布附近的模型不确定性，建立分布鲁棒的均值–方差投资组合模型。然后，作者证明最坏情况下的收益约束可以显式写成“经验收益减去一个范数折扣项”，而最坏情况下的方差优化则等价于“经验方差加

正则项”的优化问题。最后，文章进一步给出 δ 和 $\bar{\alpha}$ 的统计选择方法，使整个模型不仅在理论上成立，而且在实践中可实施。

因此，这篇文章最重要的结论是：**在投资组合选择中，分布鲁棒优化并不是对经典模型的附加修补，而是一条能够自然导出正则化、并显式处理估计不确定性的系统路径。**

2 论文二：Variance-based regularization with convex objectives

2.1 问题出发点：ERM 忽略了损失波动

这篇论文从统计学习中的经验风险最小化（ERM）出发。标准 ERM 的做法是：给定训练样本 $\{X_1, \ldots, X_n\}$，选择参数 θ 最小化经验损失

$$\frac{1}{n}\sum_{i=1}^{n} \ell(\theta, X_i).$$

这种方法关注的是训练样本上的平均表现，但作者指出，真实泛化误差并不只由平均损失决定，还与损失的方差密切相关。若某个模型虽然平均损失较低，但不同样本上的损失波动很大，那么它通常更不稳定，泛化能力也更差。

因此，仅最小化经验风险并不能充分控制泛化误差，模型还需要对损失波动进行约束。

2.2 理想目标：经验风险加方差惩罚

基于这一观察，一个自然的目标是直接最小化

$$\frac{1}{n}\sum_{i=1}^{n} \ell(\theta, X_i) \;+\; C\sqrt{\frac{\mathrm{Var}_{\hat{P}_n}(\ell(\theta, X))}{n}},$$

即“经验风险 + 方差惩罚”。第一项衡量平均损失，第二项惩罚损失的波动，本质上是在进行 bias–variance tradeoff。

这一目标在统计上很有吸引力，但计算上存在困难：即使原始损失函数 $\ell(\theta, x)$ 关于 θ 是凸的，加入方差项之后，整体目标通常也会变成非凸问题。因此，直接做方差正则化在实践中往往难以求解。

2.3 替代思路：基于 χ^2-divergence 的分布鲁棒优化

为绕开这一非凸障碍，作者没有直接优化方差正则化目标，而是引入分布鲁棒优化框架。在经验分布 $\hat{P}_n$ 周围构造一个 χ^2-divergence 邻域：

$$\mathcal{P}_n = \left\{ P : \; D_\phi(P \| \hat{P}_n) \le \frac{\rho}{n} \right\}.$$

然后定义鲁棒经验风险

$$R_n(\theta, \mathcal{P}_n) = \sup_{P \in \mathcal{P}_n} \mathbb{E}_P[\ell(\theta, X)],$$

并求解

$$\hat{\theta}_n^{\mathrm{rob}} \in \arg\min_{\theta \in \Theta} R_n(\theta, \mathcal{P}_n).$$

这个替代方案的关键优点在于：如果原始损失函数关于 θ 是凸的，那么鲁棒目标依然保持凸性，因此比直接加入方差惩罚更容易求解。

2.4 核心结果：鲁棒目标等价于方差正则化近似

文章最核心的理论结果，是给出了鲁棒风险的方差展开：

$$R_n(\theta, \mathcal{P}_n) = \mathbb{E}_{\hat{P}_n}[\ell(\theta, X)] + \sqrt{\frac{2\rho}{n} \operatorname{Var}_{\hat{P}_n}(\ell(\theta, X))} + \varepsilon_n(\theta),$$

其中 $\varepsilon_n(\theta)$ 是较小的误差项。

这说明，作者构造的鲁棒目标在本质上就是

$$\text{经验风险} + \text{方差惩罚} + \text{小误差}.$$

也就是说，分布鲁棒优化不是一个凭空引入的新目标，而是对理想方差正则化目标的凸近似。它保留了惩罚高波动解的统计思想，同时避免了直接优化方差项带来的非凸困难。

2.5 统计保证与方法代价

在建立这种等价关系之后，作者进一步证明：鲁棒解能够自动实现 bias–variance tradeoff，并满足高概率风险保证：

$$R(\hat{\theta}_n^{\mathrm{rob}}) \leq \inf_{\theta \in \Theta} \left\{ R(\theta) + 2\sqrt{\frac{2\rho}{n} \mathrm{Var}(\ell(\theta, X))} \right\} + C\frac{\rho}{n}.$$

这个结果表明，鲁棒方法会自然偏向那些总体风险低且损失波动小的参数点。

当然，作者也指出，在一些低噪声、设定良好的问题中，ERM 本身已经很有效，此时额外的鲁棒化可能带来一定偏差。不过这种代价通常是可控的，而在高方差、难样本、稀有类别等场景中，鲁棒方法通常更稳定，也更有优势。

2.6 论文主线总结

这篇论文的主线很清楚：它从 ERM 忽视损失方差这一问题出发，指出理想的“经验风险 + 方差惩罚”目标虽然合理，但通常非凸、难以优化。为此，作者引入 χ^2-divergence 球上的分布鲁棒优化，并证明其鲁棒目标等价于方差正则化目标的凸近似。最终，文章给出了一个既可计算、又有严格统计保证的鲁棒正则化方法。

因此，本文最重要的贡献在于：**它把方差正则化这个统计上自然、但计算上困难的想法，转化为了一个可求解、可分析的分布鲁棒优化框架**。

3 论文三：Robust optimization –methodology and applications

3.1 研究动机：名义最优解往往不可靠

这篇论文讨论的是更一般的鲁棒优化框架。作者指出，传统优化通常假设目标函数和约束中的数据完全准确，因此求得的是**名义最优解**。但在现实问题中，数据误差、参数扰动和实施偏差普遍存在，因此名义最优解往往非常脆弱：只要数据发生很小变化，原本可行且最优的解就可能失去可行性，或性能大幅下降。

因此，鲁棒优化的核心出发点是：优化不应只追求标称数据下的最优性，还应追求在不确定数据下的可行性和稳定性。

3.2 基本思想：从名义问题到鲁棒对应问题

为处理数据不确定性，作者把原来的单一优化问题看成一个**不确定问题族**。数据不再是固定参数，而是在一个不确定集合 U 中变化。于是，一个候选解若想真正可靠，就必须对所有属于 U 的数据都保持可行。

基于这一点，作者提出**鲁棒对应问题**（robust counterpart）：把原来仅对给定数据成立的约束，改写为对所有不确定数据都成立的约束。这样得到的解不再只是名义最优，而是在整个不确定集合上都安全的解。

3.3 论文的核心问题：鲁棒问题能否保持 tractable

鲁棒对应问题的思想很自然，但计算上会立刻带来困难，因为“对所有 $\zeta \in U$ 成立”通常意味着半无限约束。整篇论文围绕的核心问题就是：在不同类型的凸优化模型中，鲁棒对应问题能否 reformulate 成可计算的形式；若不能精确 reformulate，又能否构造安全且可计算的近似模型。

作者主要讨论了三类问题：

1. 不确定线性规划；
2. 不确定二次/二阶锥规划；
3. 不确定半定规划。

3.4 第一条主线：鲁棒线性规划

在线性规划部分，结论最为整齐。作者证明：当不确定集合 U 本身具有良好的凸结构时，鲁棒线性规划的对应问题往往仍然是 tractable 的。具体而言，原本半无限形式的鲁棒 LP 可以精确 reformulate 为：

- 线性规划（LP）；(U 是多面体）
- 二阶锥规划（SOCP）；（U 是椭球）
- 半定规划（SDP）。

这说明，在不确定线性规划中，只要不确定集合本身“可解”，鲁棒化后的问题通常仍然可解。这是鲁棒优化能够真正落地应用的重要基础。

3.5 不确定集合的几何选择

文章特别讨论了两类常见的不确定集合：区间不确定性和椭球不确定性。

区间不确定性假设每个参数可以独立地在给定区间内波动。这种建模最直接，但通常也更保守，因为它隐含允许所有参数同时达到最不利边界值。

椭球不确定性则更适合描述具有联合结构的随机扰动。与区间集合相比，它通常没那么保守，同时还能与“均值加若干倍标准差”这类统计解释联系起来。因此，不确定集合的几何形状，直接决定了鲁棒优化在安全性与保守性之间的权衡。

3.6 第二条主线：二次规划中的鲁棒化

当问题扩展到不确定凸二次约束或二阶锥规划时，情况明显变复杂。作者指出，在这一类问题中，即使不确定集合很简单，精确的鲁棒对应问题也常常已经是 NP-hard。也就是说，鲁棒化并不总能像在线性规划中那样自然保持 tractability。

为此，作者提出了**近似鲁棒对应问题**的思路：不再强求与原始鲁棒问题完全等价，而是构造一个 tractable 的保守近似。这样的近似模型具有两个特点：其可行解一定是真正鲁棒可行的，因此是安全的；同时其保守程度又可以用显式上界来刻画。

因此，在二次规划场景中，论文的重点不再是“精确 reformulate”，而是“如何得到一个既安全又不过分保守的可计算近似”。

3.7 第三条主线：半定规划中的鲁棒化

在半定规划部分，难度进一步提高。作者指出，对于不确定 SDP，即使不确定集合只是简单的椭球，精确鲁棒对应问题通常也已是 NP-hard。因此，这一部分的重点同样转向结构化近似。

作者针对 box uncertainty 和 ball uncertainty 等不同情形，构造了一类 tractable 的 SDP 近似鲁棒模型，并证明其 conservativeness 只依赖于扰动矩阵的某些低秩结构，而不依赖整个问题的巨大维数。这样一来，即使原始鲁棒 SDP 难以精确求解，仍然可以利用问题结构得到实用的近似模型。

3.8 应用部分：鲁棒性在现实问题中的价值

论文还通过多个应用实例说明鲁棒优化的实际意义，例如天线设计、NETLIB 线性规划案例、Lyapunov 稳定性分析以及桁架拓扑设计等。这些例子的共同结论是：名义最优解在现实扰动下往往非常脆弱，而鲁棒优化虽然会牺牲一部分标称最优值，却能够显著提高可行性、稳定性和实施可靠性，而且这种代价通常并不大。

因此，鲁棒性在这些问题中并不是附加改进，而往往决定了一个解是否真正可用。

3.9 论文主线总结

这篇论文从传统优化对精确数据的依赖出发，指出名义最优解在现实不确定环境下常常不可靠。随后，作者提出鲁棒对应问题的统一框架，把“不确定性下仍保持可行”直接纳入模型定义之中。在线性规划中，鲁棒问题往往可以精确 reformulate 为标准凸优化问题；而在二次规划和半定规划中，精确鲁棒化通常变得困难，于是作者进一步发展出具有理论保守性保证的 tractable 近似方法。最后，应用部分说明，这一框架能够以较小的目标代价显著提升解在现实扰动下的可靠性。

因此，这篇文章最重要的结论是：**面对不确定数据，优化不应先求名义最优再寄希望于现实偏差足够小，而应从建模开始就把不确定性纳入约束，直接求一个在允许扰动下仍然安全的解**。

4 六篇论文的方法论及其在鲁棒优化中的联系

4.1 六篇论文各自的方法论

4.1.1 Robust Optimization – Methodology and Applications

这是最基础、最经典的鲁棒优化框架。它研究的是：优化问题里的数据本身不精确，只知道它落在某个不确定集 U 里，因此要求解在所有 $\zeta \in U$ 下都可行、都安全的解。论文将这种做法称为 *robust counterpart*，即把原来只在名义数据下成立的约束，改成对所有允许扰动都成立的约束。

其核心贡献不是某个具体模型，而是一套统一方法论：给定 uncertainty set，如何把原本半无限的最坏情形问题 reformulate 成 tractable 的 LP / SOCP / SDP，或者给出保守但可算的近似。

关键词： 对象：优化问题中的系数、矩阵、向量不确定；鲁棒方式：对所有 $\zeta \in U$ 保证约束成立；核心目标：可行性与安全性；数学形式：robust counterpart；本质：几何上的集合鲁棒，而不是统计意义上的分布鲁棒。

4.1.2 Variance-based Regularization with Convex Objectives

这篇论文已经从经典 RO 走向统计学习和 DRO。作者的出发点是：ERM 只最小化平均经验损失，但泛化误差还受损失方差影响。自然地，我们会想最小化

$$\text{empirical risk} + C\sqrt{\frac{\mathrm{Var}}{n}},$$

但这个直接的 variance-regularized 目标通常是非凸的。

作者的关键做法是：不直接做“方差正则化”，而是在经验分布 $\hat{P}_n$ 周围放一个 χ^2-divergence ball，考虑 distributionally robust risk：

$$R_n(\theta, \mathcal{P}_n) = \sup_{P:\, D_\phi(P\|\hat{P}_n) \le \rho/n} \mathbb{E}_P[\ell(\theta, X)].$$

然后证明这个 robust risk 近似等于

$$\hat{\mathbb{E}}[\ell] + \sqrt{\frac{2\rho\,\mathrm{Var}_{\hat{P}_n}(\ell)}{n}} + \varepsilon_n(\theta),$$

也就是“经验风险 + 方差惩罚”的一个凸 surrogate。

关键词： 对象：经验分布本身有估计误差；鲁棒方式：对经验分布附近的分布集合取最坏期望；不确定集：χ^2-divergence ball；核心贡献：把难算的 variance regularization 变成可算的 convex DRO；意义：从“最坏约束可行”转向“最坏期望损失控制”。

4.1.3 Distributionally Robust Mean-Variance Portfolio Selection with Wasserstein Distances

这篇论文把 DRO 放到了金融投资组合里。经典 Markowitz 模型高度依赖均值和协方差估计，尤其均值估计很不稳定。因此，作者不再假设真实分布已知，而是在经验分布 P_n 周围构造一个 Wasserstein ambiguity set，做最坏情形的均值–方差组合选择。

它最重要的地方有两点：第一，它证明 Wasserstein-DRO 的 Markowitz 问题可以化成经验方差最小化加一个 regularization term，也就是说，robustness 最后又落成了正则化。第二，它不仅给出模型，还讨论 ambiguity size δ 和 robust target return $\bar{\alpha}$ 如何数据驱动地选择，因此比经典 RO 更具有统计解释。

关键词：对象：资产收益分布不确定；鲁棒方式：对 Wasserstein ball 内所有分布取 worst-case variance / mean；应用场景：Markowitz portfolio；核心贡献：Wasserstein DRO $\leftrightarrow$ regularized empirical variance minimization；特点：比经典 RO 更偏分布层面，比 variance paper 更偏金融结构化。

4.1.4 Explaining and Harnessing Adversarial Examples

这篇论文是 adversarial robustness 的起点，但严格来说，它还不是完整的 robust optimization 论文。它首先提出一个解释：神经网络对对抗样本的脆弱性，不一定是因为 “太非线性”，反而很大程度上来自高维空间中的近似线性。每个坐标上的小扰动，在高维里会累积成很大的输出变化。

在方法上，它提出了 FGSM：通过对损失做一阶近似，在 L_∞ 约束下，选取使损失上升最快的符号方向扰动，然后用这些样本做 adversarial training。

关键词：不确定性对象：输入 x 的小邻域扰动；鲁棒方式：不是对分布取 supremum，而是对局部输入扰动做一阶 worst-case 近似；核心贡献：FGSM + adversarial training 的可操作范式；局限：一步攻击，更多是 heuristic / first-order approximation，还没有形成严格的 saddle-point 框架。

4.1.5 Towards Deep Learning Models Resistant to Adversarial Attacks

这篇论文把 Goodfellow 的 heuristic 正式提升成 robust optimization / min-max 语言。它明确提出深度网络鲁棒训练的核心问题可以写成

$$\min_{\theta} \ \mathbb{E}_{(x,y)\sim D}\Big[\max_{\delta\in S} L(\theta, x+\delta, y)\Big].$$

其中，内层是攻击：在允许扰动集 S 中寻找最坏样本；外层是训练：让模型对这些最坏样本也保持较低损失。

这篇论文最关键的贡献不只是提出某种攻击，而是统一了攻击与防御：攻击是内层最大化，训练是外层最小化。它进一步提出 PGD 作为 “first-order adversary” 的通用近似，并指出 adversarial training 的本质就是在优化这个 saddle-point problem。同时，论文还说明模型容量对鲁棒性非常重要。

关键词：对象：输入扰动；鲁棒方式：明确的 min-max robust optimization；不确定集：通常是 L_∞ 球；核心贡献：把 adversarial training 从 heuristic 提升为标准的 saddle-point optimization。

4.1.6 Certifying Some Distributional Robustness with Principled Adversarial Training

这篇论文可以看成是把 Madry 的输入扰动 min-max，再进一步放进 distributionally robust optimization 的框架里。它不是直接写成

$$\sup_{\|\delta\|\le\epsilon} \ell(\theta, x+\delta, y),$$

而是先在分布层面定义一个 Wasserstein ball，考虑

$$\min_{\theta} \sup_{P\in\mathcal{P}} \mathbb{E}_P[\ell(\theta; Z)].$$

然后对这个问题做 Lagrangian penalty relaxation，得到 robust surrogate

$$\phi_\gamma(\theta; z_0) = \sup_{z} \left\{\ell(\theta; z) - \gamma c(z, z_0)\right\}.$$

于是最终训练目标变成对这一 surrogate 的经验平均最小化。

它与 Madry 的关键区别在于：Madry 直接做约束式输入球内层最大化；Sinha 等人做的是分布鲁棒 + Wasserstein ball + 拉格朗日罚函数。它的额外贡献在于：一方面，对于 smooth loss，当 γ 足够大时，内层 surrogate 可变成强凹问题，因此更有优化理论支撑；另一方面，它还给出 population worst-case loss 的 certificate。

关键词： 对象：分布层面与输入层面的双重不确定性；鲁棒方式：Wasserstein DRO + adversarial training；核心贡献：把 adversarial training 嵌入分布鲁棒优化框架；特点：可看作 “DRO 版 adversarial training”。

4.2 它们在鲁棒优化上的联系

4.2.1 共同结构

这六篇论文都可以写成某种“外层做决策，内层让对手挑选最坏不确定性”的形式：

经典 RO：外层选 x，内层让数据 $\zeta \in U$ 变坏；

Variance paper：外层选 θ，内层在 χ^2-ball 内挑最坏分布 P；

Portfolio paper：外层选组合 ϕ，内层在 Wasserstein ball 内挑最坏收益分布；

Goodfellow：外层选参数 θ，内层近似挑最坏输入扰动 η，但仍是 heuristic；

Madry：外层选 θ，内层在输入球 S 里精确定义 worst-case 扰动；

Sinha：外层选 θ，内层在 Wasserstein 分布球内挑最坏分布，再通过拉格朗日化转成点级别的对抗扰动。

因此，它们都可以归入如下统一模板：

$$\min_{\text{decision}} \sup_{\text{uncertainty in a set}} \text{loss/risk}.$$

4.2.2 从 RO 到 DRO 再到 Adversarial Training 的演化

从方法论的发展来看，这六篇论文形成了一条清晰的演化路径。

Ben-Tal 和 Nemirovski 代表经典鲁棒优化，其核心是不确定数据落在一个集合里，因此要求解对这个集合中所有可能扰动都稳健的解，这属于集合鲁棒。

Duchi 和 Namkoong 则将不确定性从单个参数提升到底层分布，在经验分布附近考虑 worst-case expectation，这属于分布鲁棒。

Blanchet、Chen 和 Zhou 将这一分布鲁棒思想应用到资产收益分布中，并给出 Wasserstein-regularization 的解释，使 DRO 在金融投资组合中获得具体化表达。

Goodfellow 到 Madry 则把“最坏情况”进一步缩小到单个输入的局部邻域。Goodfellow 给出了 heuristic 的攻击与训练方式，Madry 则把这一思路正式写成标准 min-max 问题，从而奠定了对抗训练的 robust optimization 表达。

Sinha 等人进一步把 adversarial training 提升回 DRO 语言，说明输入攻击可以理解为 Wasserstein-ball 分布扰动在样本层面的具体实现。

4.3 它们的主要区别

4.3.1 不确定性放置的位置不同

经典 RO 处理的是优化问题中系数、矩阵、向量的不确定性；

Variance paper 和 portfolio paper 处理的是经验分布或收益分布的不确定性；

Goodfellow、Madry 和 Sinha 更关注输入空间中的局部扰动，其中 Sinha 又进一步把这种输入扰动提升到了 Wasserstein 分布鲁棒的层面。

4.3.2 理论目标不同

经典 RO 偏向工程中的可行性与安全性；
Variance paper 偏向统计学习中的泛化与 bias-variance tradeoff；
Portfolio paper 偏向金融参数不稳定条件下的 out-of-sample 表现；
Goodfellow 偏向现象解释与实用攻击/训练方法；
Madry 偏向明确定义的安全保证，即 first-order adversary robustness；
Sinha 偏向带 certificate 的分布鲁棒 adversarial training。

4.3.3 整体分层

如果从方法论层面概括，这六篇论文大致可以分成三层。

第一层是经典鲁棒优化：*Robust Optimization – Methodology and Applications*；核心问题是：参数不确定时，如何保证解仍然安全可行。

第二层是统计与分布鲁棒优化：*Variance-based Regularization with Convex Objectives*；*Distributionally Robust Mean-Variance Portfolio Selection with Wasserstein Distances*；核心问题是：经验分布不可靠时，如何让模型或组合在分布偏移下仍然稳健。

第三层是深度学习中的对抗鲁棒：*Explaining and Harnessing Adversarial Examples*；*Towards Deep Learning Models Resistant to Adversarial Attacks*；*Certifying Some Distributional Robustness with Principled Adversarial Training*；核心问题是：输入受到对抗性微扰时，如何训练出在最坏局部邻域内仍然稳定的模型。

5 robust return prediction

5.1 模型 0：Conditional Autoencoder Baseline

基线模型。

结构 直接采用 *Autoencoder Asset Pricing* 那篇论文的核心写法：

$$\hat{r}_{i,t} = \beta_\theta(z_{i,t-1})^\top f_\phi(x_t)$$

其中：

- $z_{i,t-1}$：个股特征；
- $\beta_\theta(\cdot)$：beta network；
- x_t：characteristic-managed portfolios；
- $f_\phi(\cdot)$：factor network。

5.2 模型 1：Variance-Regularized Conditional Autoencoder

第一版 robust model。

核心思想 利用 Variance-based 论文的思想，不显式构造 adversarial sample，而是先把 robustification 写成一种可训练的 regularization。

既然 robust risk 近似于 empirical risk + variance term，就可以把模型的 loss 写成：

$$\mathcal{L} = \underbrace{\frac{1}{NT}\sum_{i,t}(r_{i,t} - \hat{r}_{i,t})^2}_{\text{prediction loss}} + \lambda \cdot \Omega_{\text{var}}(\theta)$$

其中 Ω_{var} 可以直接对 mini-batch loss 方差加惩罚

$$\Omega_{\text{var}}(\theta) = \mathrm{Var}_{\text{batch}}\big((r - \hat{r})^2\big)$$

其含义是：不只让平均 loss 小，还要让 loss 的波动小。

5.3 模型 2：Wasserstein-Adversarial Conditional Autoencoder

robust AI 版本。

核心思想 用 Portfolio 论文的 Wasserstein ambiguity set 思想，把输入特征的局部不确定性写成一个邻域；再用 adversarial training 的方式做神经近似。

第二篇论文告诉我们：围绕经验分布定义 Wasserstein 球是一种自然的鲁棒方式。

结构 主干不变：

$$\hat{r}_{i,t} = \beta_\theta(z_{i,t-1})^\top f_\phi(x_t)$$

但在训练时，对特征加入扰动：

$$\tilde{z}_{i,t-1} = z_{i,t-1} + \Delta_{i,t}, \qquad \Delta_{i,t} \in \mathcal{U}_\delta$$

然后最小化最坏情形损失：

$$\min_{\theta,\phi} \frac{1}{NT}\sum_{i,t} \max_{\Delta_{i,t}\in\mathcal{U}_\delta} \Big(r_{i,t} - \beta_\theta(z_{i,t-1} + \Delta_{i,t})^\top f_\phi(x_t)\Big)^2$$

实际 精确求解内层最优化问题？在神经网络中，：

- FGSM：一步梯度扰动；
- PGD：多步梯度扰动。

也就是说，把 Wasserstein / DRO 的原则落实成 adversarial training。

5.4 模型 3：Latent-Stable Beta Autoencoder

核心思想 这里不只是要求 return prediction 在扰动下稳定，而是更进一步要求：

特征 $\to$ beta 的映射本身要稳定。

结构 仍然采用：

$$\hat{r}_{i,t} = \beta_\theta(z_{i,t-1})^\top f_\phi(x_t)$$

然后定义 clean 和 perturbed beta：

$$\beta_{i,t-1}^{\text{clean}} = \beta_\theta(z_{i,t-1}), \qquad \beta_{i,t-1}^{\text{adv}} = \beta_\theta(z_{i,t-1} + \Delta_{i,t})$$

加入一致性正则项：

$$\mathcal{L}_{\text{cons}} = \frac{1}{NT} \sum_{i,t} \left\| \beta_{i,t-1}^{\text{clean}} - \beta_{i,t-1}^{\text{adv}} \right\|^2$$

总损失写为：

$$\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda \mathcal{L}_{\text{adv}} + \gamma \mathcal{L}_{\text{cons}}$$

它和模型 2 的区别

- 模型 2 是“预测层面鲁棒”；
- 模型 3 是“表示层面鲁棒”。